

Tugas Besar

IF3211 Komputasi Domain Spesifik

Estimasi Distribusi Fase Siklus Sel dari Data Flow Cytometry Menggunakan Model Dean-Jett-Fox



Disusun oleh
Kelompok 0

Jacob Reinhard Marudut Siagian	18223026
Stevan Einer Bonagabe	18223028
Michael Ballard Isaiah Silaen	18223080
M Khalfani Shaquille	18223104

PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG

2026

1. Pendahuluan

1.1 Konsep Biologi

Pertumbuhan seluler dan persiapan sel untuk membelah di antara dua pembelahan yang berurutan dikenal sebagai siklus sel. Siklus ini secara umum dibagi ke dalam empat fase utama, yaitu fase G1 (gap 1), S (sintesis DNA), G2 (gap 2), dan M (mitosis). Hal ini juga berlaku pada tahapan perkembangan sel tumor. Sel kanker seringkali menunjukkan proliferasi yang tidak terjadwal, dan disregulasi pada siklus sel ini diyakini sebagai langkah awal dari karsinogenesis yang esensial untuk invasi tumor serta metastasis. Selain itu, identifikasi perubahan pada progresi siklus sel juga sangat krusial dalam pengujian obat-obatan guna mengklarifikasi mekanisme kerjanya.

Salah satu pendekatan yang paling umum untuk mengidentifikasi fase-fase siklus sel ini adalah melalui analisis kandungan DNA. Sel-sel yang berada pada fase G1 dan G0 secara konsisten memiliki kandungan DNA separuh dari sel-sel yang berada di fase G2 dan M. Dalam praktiknya, DNA diwarnai menggunakan pewarna pendar fluoresens, lalu sinyal fluoresensinya dianalisis. Representasi histogram dari kandungan DNA ini kemudian memungkinkan peneliti untuk mengestimasi jumlah sel yang berada di fase G1/G0, fase S, dan fase G2/M.

1.2 Metode

Sel-sel yang memiliki kandungan DNA yang sama dapat mengikat zat pewarna fluoresens dengan cara yang berbeda-beda pada struktur DNA mereka. Akibat adanya variasi ini, analisis visual murni terhadap kandungan DNA tidak memberikan diskriminasi yang mudah dan akurat untuk memisahkan fase G1/G0, S, dan G2/M. Oleh karena itu, berbagai pendekatan matematis telah dikembangkan guna membantu mengestimasi fraksi sel pada masing-masing fase tersebut secara lebih presisi.

Salah satu pendekatan komputasi yang digunakan adalah pemodelan *Dean-Jett-Fox* yang juga melibatkan algoritma matematis seperti algoritma Michael H. Fox. Metode ini bekerja dengan melakukan pencocokan kurva (*curve fitting*) pada data histogram *flow cytometry*. Secara teknis, model komputasi ini memanfaatkan distribusi probabilitas *Gaussian* untuk menangkap dan memodelkan populasi puncak pada sel fase G1 maupun G2/M, yang kemudian digabungkan dengan fungsi polinomial untuk merepresentasikan distribusi populasi sel yang menyebar pada fase S.

1.3 Tinjauan Pustaka

Landasan awal untuk pendekatan komputasi matematis dalam analisis histogram siklus sel dipelopori oleh Dean dan Jett pada tahun 1974, di mana mereka merumuskan analisis matematis pertama untuk distribusi DNA dari data *flow microfluorometry*. Metode pengukuran tersebut kemudian disederhanakan lebih lanjut oleh Dean pada tahun 1980 untuk memudahkan analisis distribusi DNA. Selanjutnya, pendekatan ini dikembangkan menjadi algoritma komputer spesifik untuk distribusi DNA sinkron oleh Fox pada tahun 1980.

Hingga saat ini, algoritma Michael H. Fox tersebut diadaptasi secara luas oleh berbagai perangkat lunak analisis sitometri modern, seperti *Kaluza Analysis Software*, untuk menghitung persentase fase sel. Dalam proyek komputasi ini, implementasi model algoritma tersebut akan divalidasi memanfaatkan *dataset* histogram *flow cytometry* eksperimental riil yang dapat diakses secara publik melalui repositori terbuka seperti *FlowRepository* ataupun data *GEO* dari NCBI.

1.4 Rumusan Masalah

Berdasarkan latar belakang tersebut, proyek ini merumuskan tiga pertanyaan penelitian utama.

- Bagaimana mengimplementasikan algoritma model *Dean-Jett-Fox* secara komputasional menggunakan bahasa pemrograman Python untuk melakukan *curve fitting* pada histogram DNA dari data *flow cytometry*?
- Bagaimana tingkat kesesuaian (*fitting accuracy*) dan akurasi estimasi kuantitatif persentase sel pada fase G1, S, dan G2/M yang dihasilkan oleh model komputasi ini saat divalidasi langsung dengan data eksperimental asli?
- Bagaimana profil distribusi fase siklus sel ini dapat divisualisasikan serta dianalisis perbedaannya ketika membandingkan populasi sel normal dengan sel kanker atau sel yang telah diberi perlakuan obat tertentu?

1.5 Tujuan

Tujuan utama dari pengembangan proyek ini adalah agar kami dapat menunjukkan pemahaman mengenai dasar-dasar biologi dalam mengembangkan solusi berbasis komputing. Selain itu, proyek ini bertujuan untuk merealisasikan pemahaman tersebut ke dalam implementasi algoritma yang fungsional menggunakan bahasa pemrograman Python. Penelitian ini juga bertujuan untuk menjelaskan bagaimana model komputasi yang diusulkan dapat berkontribusi terhadap ilmu pengetahuan. Luaran dari proyek ini diharapkan mampu menyediakan perangkat bantu komputasi kuantitatif untuk mendukung interpretasi biologis, baik itu terkait karakteristik siklus proliferasi sel tumor maupun dalam mengevaluasi efektivitas respons seluler terhadap intervensi medis.

2. Metode


2.1 Model yang Digunakan

Model *Dean-Jett-Fox* pada proyek ini memodelkan histogram DNA sebagai gabungan komponen berikut:

- G1 dan G2/M sebagai Gaussian berbasis area (luas kurva merepresentasikan proporsi sel). Mean G2/M ditetapkan sebagai mean G1 + delta, sehingga rasio $4N/2N$ bisa dikontrol oleh optimisasi.
- Fase S sebagai polinomial kuadratik non-negatif di antara puncak G1 dan G2/M. Komponen ini dinormalisasi berdasarkan area dan kemudian di-*broaden* dengan kernel Gaussian yang diturunkan dari coefficient of variation (CV) G1 agar lebar distribusi menyerupai sinyal yang terobservasi.
- Debris sebagai eksponensial menurun di sisi kiri histogram untuk menampung sinyal rendah, serta *background* konstan untuk menyerap baseline datar.

Parameter dicari dengan *least-squares* berbobot menggunakan bobot $\sqrt{\text{count}}$ agar bin dengan count tinggi tidak mendominasi penuh. Optimisasi juga menambahkan regularisasi ringan untuk menjaga rasio G2/G1 dan lebar puncak tetap berada pada rentang biologis yang wajar. Output utama adalah persentase fase (G1, S, G2/M) serta metrik kualitas fit (SSE, RMSE, R^2 , weighted SSE, reduced chi-square) dan *warning parameter*.

2.2 Flowchart



Gambar 2.1 Flowchart Metode Jean-Fox

2.3 Kode Program

Struktur kode dipisah agar model dapat digunakan ulang dan notebook tetap fokus pada analisis:

- Pembacaan metadata FCS: script `inspect_fcs_metadata.py` membaca header/text segment FCS untuk memilih channel DNA/PI secara transparan.
- Preprocessing histogram: script `preprocess_zenodo_histograms.py` membaca FCS, memilih channel PI-A, menyaring nilai, lalu membuat histogram dan ringkasan JSON/CSV.
- Model dan fitting: modul `models/dean_jett_fox.py` memuat fungsi `fit_dean_jett_fox` beserta komponen Gaussian, polinomial S, broadening, debris, dan evaluasi fit.
- Notebook: memanggil preprocessing bila ringkasan belum ada, menjalankan fitting untuk seluruh sampel, lalu merangkum metrik dan plot.
- Website/API: Layanan web untuk menampilkan daftar dataset dan menjalankan fitting Dean Jett Fox melalui request HTTP.

3. Hasil & Diskusi


3.1 Analisis Kuantitatif

Analisis kuantitatif mengevaluasi kualitas fitting model Dean-Jett-Fox serta ringkasan numerik persentase fase sel (G1, S, G2/M). Ukuran utama yang digunakan adalah SSE, RMSE, R^2 , weighted SSE, dan reduced chi-square. Secara umum:

- R^2 mengindikasikan seberapa besar variasi histogram yang dapat dijelaskan oleh model. Nilai mendekati 1 menunjukkan kecocokan yang lebih baik.
- RMSE menggambarkan rata-rata kesalahan absolut antara kurva model dan data.
- Reduced chi-square menilai kecocokan model terhadap data berbobot; nilai yang tinggi mengindikasikan residual berbobot masih besar sehingga interpretasi biologis harus lebih hati-hati.

- Rasio G2/G1 dipakai sebagai pemeriksaan biologis karena populasi 4N idealnya berada sekitar dua kali posisi 2N.

Berdasarkan hasil fitting, persentase G1, S, dan G2/M dapat diringkas per kondisi (AI vs AX) dan timepoint (0, 24, 48, 72 jam) untuk melihat tren kuantitatif. Jika ada sampel dengan R^2 rendah atau reduced chi-square tinggi, sampel tersebut dicatat sebagai fit lemah sehingga persentase fase yang dihasilkan tidak dijadikan dasar kesimpulan utama.




Gambar 3.1 Plot Estimasi Distribusi Siklus Sel pada Kondisi AI dan AX

3.2 Analisis Kualitatif

Analisis kualitatif dilakukan dengan meninjau bentuk histogram dan kurva komponen model (G1, S, G2/M, debris, background) untuk memastikan interpretasi kuantitatif konsisten dengan bentuk visual data.

- Puncak G1 tampak sebagai puncak utama pada intensitas lebih rendah (2N).
- Fase S tampak sebagai distribusi kontinu di antara puncak G1 dan G2/M; model menangkapnya melalui polinomial kuadrat yang di-*broaden*.
- Puncak G2/M tampak sebagai puncak/shoulder pada intensitas lebih tinggi (4N). Ketidakesuaian yang sering muncul secara kualitatif adalah:
- Ekor distribusi yang panjang di sisi kiri histogram (indikasi debris/low-DNA).
- Puncak G2/M yang tidak jelas (sinyal lemah atau tumpang tindih dengan noise).
- Residual yang berpola sistematis (misalnya selalu positif di area S), menandakan bentuk histogram belum sepenuhnya dijelaskan oleh model.



Gambar 3.2 Plot Histogram PI-A

3.3 Analisis Hasil Dalam Konteks Biologi

Secara biologis, perubahan proporsi G1, S, dan G2/M mencerminkan dinamika proliferasi sel. Estimasi fase dari model Dean-Jett-Fox menunjukkan bagaimana distribusi DNA content berubah pada kondisi AI dan AX sepanjang timepoint.

- Jika G1 dominan, populasi cenderung berada pada fase pertumbuhan/istirahat (2N) dan laju sintesis DNA relatif rendah.
- Jika S meningkat, populasi menunjukkan aktivitas replikasi DNA yang lebih aktif.
- Jika G2/M meningkat, populasi bergerak menuju atau berada dalam fase pembelahan.

Perbandingan AI vs AX dapat ditafsirkan sebagai perbedaan pola distribusi fase menurut model, bukan bukti kausal biologis langsung, karena dataset tidak memiliki label fase individual dan gating biologis lengkap. Hasil yang paling kuat secara biologis adalah sampel dengan kualitas fit yang baik (misalnya R^2 tinggi dan reduced chi-square rendah). Sampel dengan kualitas fit lemah harus diperlakukan sebagai indikasi kasar dan tidak dijadikan kesimpulan utama.

4. Penutup

4.1 Kesimpulan

Histogram PI-A dari dataset Zenodo 14928071 dapat dianalisis dengan model Dean-Jett-Fox untuk memperkirakan distribusi fase G1, S, dan G2/M. Peningkatan model dengan polynomial S phase, *broadening*, *weighted residual*, serta komponen *debris* dan *background* membuat pemisahan komponen lebih sesuai dengan konsep asli analisis DNA histogram dibanding bentuk S yang simetris tetap.

Hasil estimasi memberikan gambaran kuantitatif tentang perubahan distribusi fase pada kondisi AI dan AX sepanjang *timepoint* 0 sampai 72 jam. Sampel dengan fit kuat dapat ditafsirkan sebagai estimasi fase yang lebih stabil, sedangkan sampel dengan fit lemah, residual berpola, atau *warning parameter* harus diperlakukan sebagai hasil yang terbatas. Secara keseluruhan, pendekatan ini menunjukkan bagaimana pemodelan komputasi dapat menghubungkan konsep siklus sel dengan data *flow cytometry* nyata secara terukur dan kritis.

4.2 Pengembangan Lanjutan

Pengembangan lanjutan yang realistis adalah memperkaya *preprocessing* dengan *gating multi-parameter* untuk mengurangi *debris*, *doublet*, dan *event* abnormal sebelum histogram PI-A dibentuk. Ini bisa meningkatkan stabilitas fitting dan menurunkan residual berbobot, sehingga interpretasi fase lebih kuat. Selain itu, model dapat diperluas dengan penanganan variasi baseline dan komponen noise yang lebih fleksibel (misalnya *background* bertingkat atau *mixture* ringan) agar dapat menyesuaikan data dengan karakteristik instrumen yang berbeda.

Di sisi validasi, langkah berikutnya adalah menguji model pada dataset dengan *ground truth* fase atau dataset dengan anotasi yang lebih lengkap untuk mengukur akurasi estimasi fase secara kuantitatif. Validasi silang antar dataset dan perbandingan dengan perangkat lunak analisis komersial juga bisa menjadi bukti eksternal yang memperkuat kredibilitas model.

5. Daftar Pustaka

Ligasová, A., Frydrych, I., & Koberna, K. (2023). Basic methods of cell cycle analysis. International Journal of Molecular Sciences, 24(4), 3674. <https://pmc.ncbi.nlm.nih.gov/articles/PMC9963451/>

Dean, P. N., & Jett, J. H. (1974). Mathematical analysis of DNA distributions derived from flow microfluorometry. *Journal of Cell Biology*, 60(2), 523-527. <https://doi.org/10.1083/jcb.60.2.523>

Fox, M. H. (1980). A model for the computer analysis of synchronous DNA distributions obtained by flow cytometry. *Cytometry*, 1(1), 71-77. <https://doi.org/10.1002/cyto.990010114>